

## 周报（2023. 3.28-2023.4.4）姓名：孙瑞阳

### 每日小结

	周一	周二	周三	周四	周五
早	Autoformer 代码，上课	大数据集调参，上课	大数据集处理，上课	上课，大数据集处理	环境配置
中	Timenet 代码，上课	论文阅读	整理代码	大数据集多线程预处理，上课	大数据集代码套入
晚	上课，Autoformer	组会	大数据集处理	大数据集处理	跑 Timenet

注：简单表述当前时间段工作，如看文献 1，整理数据等

### 科研详情

#### 文献阅读

##### 文献1

题目: Spatio-Temporal Graph Neural Networks for Predictive Learning in Urban Computing: A Survey

作者: Guangyin Jin, Yuxuan Liang, Yuchen Fang, Jincan Huang, Junbo Zhang, Yu Zheng

出处: arxiv 2023

##### 方法:

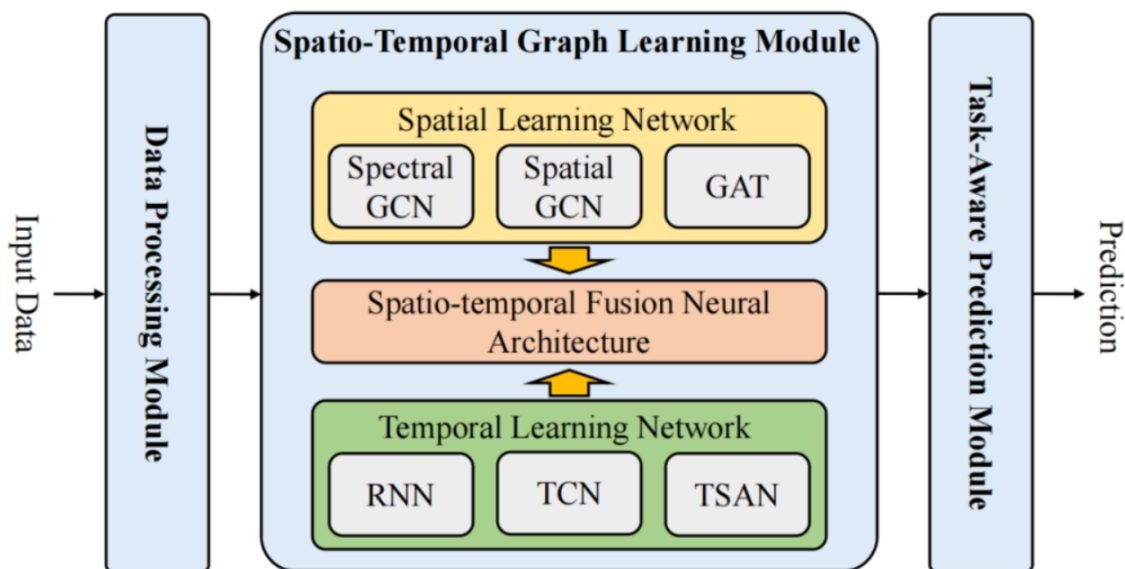
本文对城市计算中用于预测学习的时空图神经网络(STGNNs)进行了系统的综述。

用于预测学习的 STGNN 的基本框架包含三个主要模块——数据处理模块(DPM)、时空图学习模块(STGLM)和任务感知预测模块(TPM)。对于城市计算中的预测学习任务，DPM 旨在从原始数据中构建时空图数据，STGLM 旨在从复杂社会系统中捕获隐藏的时空依赖关系，TPM 旨在将来自 STGLM 的时空隐藏表示映射到下游预测任务的空间中。

如下图，STGLM 是 STGNN 中最关键的部分，STGNN 通常通过一定的时空融合神经架构将空间学习网络和时间学习网络有机结合。

对于空间学习网络，谱图卷积网络(spectral GCNs)、空间图卷积网络(spatial GCNs)和图注意力网络(GATs)都可以作为选择模型。

对于时间学习网络，循环神经网络(RNNs)、时间卷积网络(TCNs)和时间自注意力网络(tans)都可以作为选择的模型。



启发:

1. 对于时间学习网络，循环神经网络(RNNs)、时间卷积网络(TCNs)和时间自注意力网络(tans)都可以作为选择的模型，我目前的工作也是缺少了自注意力网络(tans)的部分，仅用到了 ConvTransformer 方法，需要进一步补充实验。
2. 文章整理了时序方法的开源代码，已经在阅读代码，尝试能否复现：

Temporal Dependencies Learning Methods	Muti-Scale Temporal Learning	STGNN [16]	<a href="https://github.com/LMissher/STGNN">https://github.com/LMissher/STGNN</a>
	Multi-Granularity Temporal Learning	ASTGCN [190]	<a href="https://github.com/guoshnBJTU/ASTGCN-r-pytorch">https://github.com/guoshnBJTU/ASTGCN-r-pytorch</a>
	Decomposition Temporal Learning	FC-GAGA [193]	<a href="https://github.com/boreshkinai/fc-gaga">https://github.com/boreshkinai/fc-gaga</a>
		StemGNN [195]	<a href="https://github.com/microsoft/StemGNN">https://github.com/microsoft/StemGNN</a>
		STWave [194]	<a href="https://github.com/LMissher/STWave">https://github.com/LMissher/STWave</a>

3. PredRNN, PredRNN++,MIM 也是基于循环神经网络(RNNs)和 Transformer 改造的网络，需要多多学习

## 文献2

题目: Traffic Flow Prediction via Spatial Temporal Graph Neural

作者: X Wang, Y Ma, Y Wang, W Jin, J Yu

出处: ACM

方法:

- 传统方法在时间和空间的依赖性捕捉上有明显的不足
- 本文提出一个新的时空图神经网络，它可以全面的捕捉时空关系，该网络提供一个可学习的位置注意力机制

本文所提出的时空图神经网络框架如图所示。它主要由三个部分组成：

- 1) 空间图神经网络 (S-GNN) 层，旨在捕获通过交通网络的道路之间的空间关系；
- 2) GRU 层，该 GRU 层是用来按顺序捕获时间关系（或局部时间相关性）；
- 3) Transformer 层，其目的是直接捕获序列中的长期时间依赖性（或全局时间依性）。其中，S-GNN 层用于建模节点之间的空间关系，并将其应用于 GRU 单元的输入和隐藏表示。需要注意的是 GRU 层和 Transformer 层都用于分别捕获每个节点的时间依赖性，但是分别是从不同角度捕获时间依赖性。

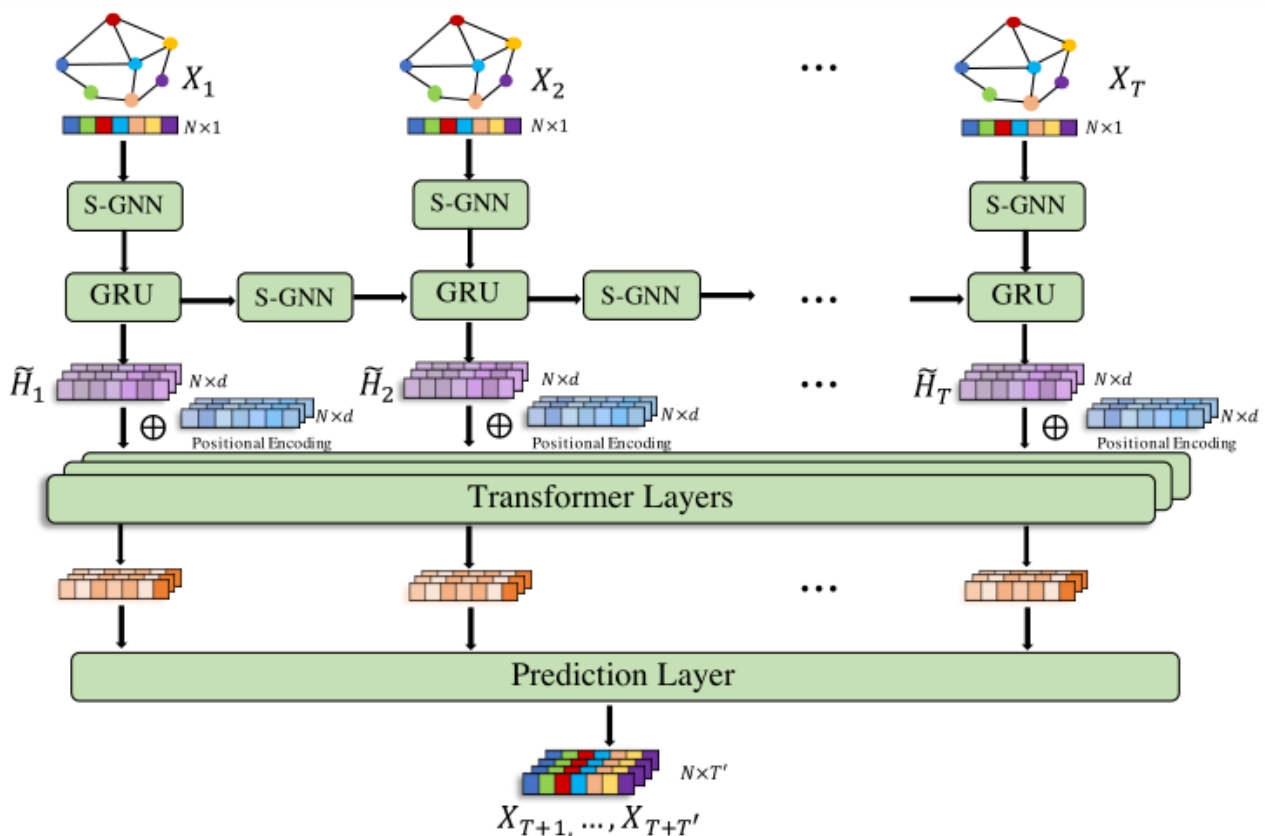


Figure 1: The Proposed Spatial Temporal Graph Neural Network Framework

本文中 Transformer 总体结构如下图所示：

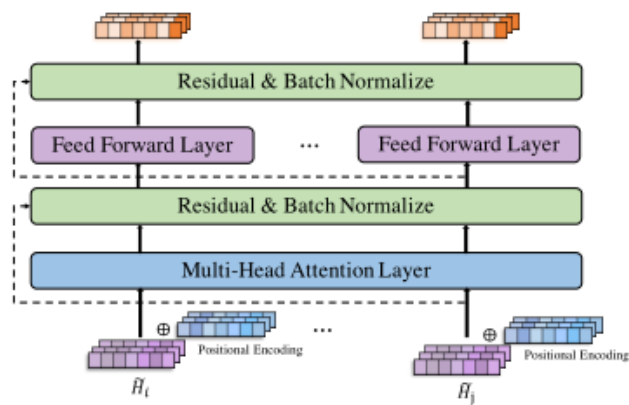


Figure 2: The Transformer Layer

最后在 Transformer 层的末端接上一个 Prediction Layer，一个普通的前馈神经网络，直接输出未来  $T'$  个时间步的交通信息。论文中用 MAE 作为整体模型训练的损失函数。

启发：

1. 本文运用 RNN 于较长序列仍然会带来误差积累，并且 RNN 模型的运算效率并不高，可以考虑运用一维卷积模型对于短时依赖进行捕捉。
2. 可以借鉴思路，本文把 transformer 和 RNN 结合，得到结合时间维度的局部特征和全局特征

## 工作进展

1: 阅读文献；


2: 尝试增加 loss，还没跑通

3: 多线程处理社交数据完毕，大数据集已经跑通，已经跑了两天，还没跑完



在前 20 个 epoch 的结果: **VIT+ConvTransformer>VIT+DPN> VIT+DPN+CBAM 通道**

4: 还在死磕 Timenet 和 Autoformer 的代码，因为这是比 ConvTransformer 更新的时序方法，还是想做出来

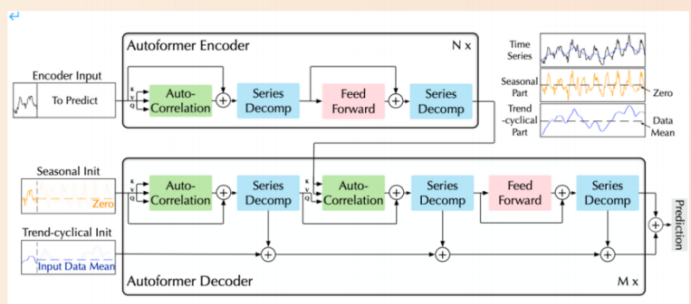
DPN换成了Timenet或者Autoformer，代码复杂，参数很多，搞懂每个参数都花费了很多时间，还是一直有问题，本周主要精力都花费在了这里。。



Timenet (ICLR 2023)




Autoformer (NeurIPS 2021)



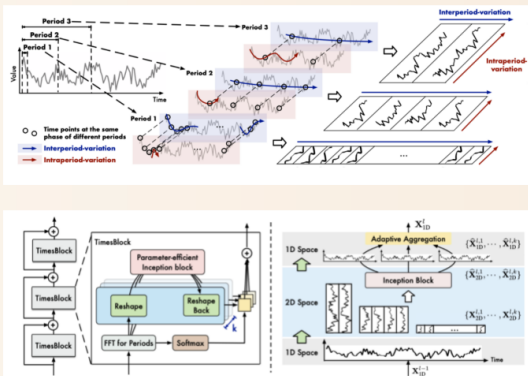
## 下周计划

- 1: URFC大数据集需要调参
- 2: 修改loss，目前还在学习
- 3: TimeNet和Autoformer还是想试试看能不能跑通，在努力搞懂

DPN换成了Timenet或者Autoformer，代码复杂，参数很多，搞懂每个参数都花费了很多时间，还是一直有问题，本周主要精力都花费在了这里。。



Timenet (ICLR 2023)



Autoformer (NeurIPS 2021)

