

每日小结

	周一	周二	周三	周四	周五
早	精修论文	精修论文	精修论文	精修论文	对比实验代码
中	画图	精修论文	精修论文	精修论文	跑实验
晚	精修论文		精修论文	论文绘图	精修论文

注：简单表述当前时间段工作，如看文献1，整理数据等

科研详情

文献阅读

**文献 1**

**题目:** A unified deep learning framework for urban functional zone extraction based on multi-source heterogeneous data

**作者:** Weipeng Lu, Chao Tao, Haifeng Li, Ji Qi, Yansheng Li

**出处:** RSE 2022

**方法:**

本文设计了一个用于学习互补特征的，包含两个 CNN 模型分支和一个融合模块的深度学习网络。其中一个 CNN 分支用于从切片的遥感影像中提取视觉特征，另一个分支用于从 POI 热力图中提取社会特征。最后，两种特征经过一个特征注意力模块进行特征融合。


在融合中，本文考虑到城市功能区之间的空间关系可以表示为局部空间关系和全局空间关系，因此联合使用了 CNN 和 RNN 分别对这两种空间关系进行特征的提取。并设计了一个交叉传递单元对二者进行特征融合。

（他的工作只有空间关系，静态 POI 和静态 RSI 融合）

*I. Complementary feature learning and fusing in single UFZ*

*II. Spatial relationship modeling between UFZs*

互补特征的协同机制（这个做的比较有意思）



社会特征权重直方图

首先，社会特征权重在商业区、工业区、机构上的峰值要大于 0.5，这也就意味着这些类别更加依赖社会特征。而在工地、水域上，其峰值则小于 0.5，意味着视觉特征对这两类的提取更加重要。因此，对于大多数的城市功能区提取而言，这种协同机制可以理解为影像和 POIs 一方作为主要特征源而另一方作为辅助特征源。

其次，社会特征权重在城市绿地、住宅区和交通上的峰值则接近 0.5，且其方差相较于其他的类别而言更加的大，这也就意味着这些类别的权重分布范围更广，不能笼统地定论视觉特征和社会特征何者占主要贡献，而是对于具体的场景，网络会动态地计算出两种类别的权重。

实验结果：

表1 消融实验设计及实验精度

Exp. #	Strategy						Kappa
	RSI	POI	LWM	FAFS	L-SPA	G-SPA	
1	√						0.7263
2	√	√					0.8172
3	√	√	√				0.8238
4	√	√	√	√			0.8328
5	√	√	√	√	√		0.8536
6	√	√	√	√		√	0.8527
7	√	√	√	√	√	√	0.8592

表2 弃用不同类型的POI对提取结果的影响

Drop POI category	Kappa	Decreasing rate of Kappa (%)
residence	0.8313	3.25
institution	0.8375	2.53
nature	0.8407	2.15
airport	0.8499	1.08
public service	0.8438	1.79
retail	0.851	0.95
hotel	0.8544	0.56
supermarket	0.8528	0.74
using all	0.8592	/

启发:

1. 主要参考了他的论文图，美化了自己的图
2. 学习了他的论文思路，修改自己论文的不足

## 文献2

题目: **Representing Long-Range Context for GraphNeural Networks with Global Attention**

作者: Zhanghao Wu, Paras Jain, Matthew A. Wright, Azalia Mirhoseini, Joseph E. Gonzalez, Ion Stoica

出处: NIPS 2021

方法:

本文提出了一种新的图神经网络架构 Graph Transformer (GraphTrans), 以学习图中的长程依赖关系。

通过在标准 GNN 模块之后添加一个 Transformer 子模块, GraphTrans 可以显式地计算图中所有节点对之间的关系, 从而学习全局信息。使用 GNN 子模块学习局部的短程关系, 使用 Transformer 子模块学习长程的全局关系。删掉位置编码使得 Transformer 对图的节点顺序不敏感, 因此适合用于建模图结构。

Code for GraphTrans is available at <https://github.com/ucbrise/graphtrans>

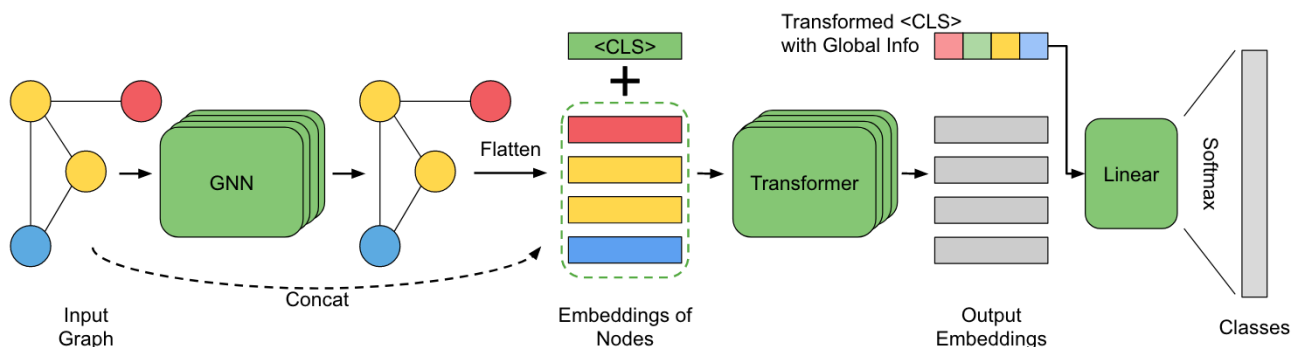


Figure 1: Architecture of GraphTrans. A standard GNN submodule learns local, short-range structure, then a global Transformer submodule learns global, long-range relationships.

- GNN 子模块:用于学习节点的局部邻域信息
- Transformer 子模块:用于学习全局的长程依赖关系

启发:

1. 在该模型中，删掉位置编码使得Transformer对图的节点顺序不敏感,因此适合用于建模图结构。比较适合于我建立的 Graph
2. GNN部分可以替换为任意的GNN网络，比较灵活，可以尝试做为下个工作的 Baseling
3. 有代码，可以直接试一下效果。代码在看

#### 工作进展

- 1: 阅读文献;
- 2: 精修论文，所有图都重画
4. 跑了和两篇论文的对比实验:

	Accurarcy	F1	Kappa
ResNet18 + Bilstm	0.642	0.600	0.576
Se-ResNeXt50 + DPN26	0.674	0.649	0.616
Ours	<b>0.695</b>	<b>0.684</b>	<b>0.641</b>

- 5.增加了论文里所有实验的 Kappa 指标

#### 下周计划

1. 投递论文
2. 尝试文献二的图 Transformer 代码